

Predicción del éxito académico en educación superior

Enrique Capella Magallón
Proyecto final de Aprendizaje Automático
Curso 2025/2026

Resumen

Este informe estudia un conjunto de 4424 estudiantes de educación superior con variables demográficas, socioeconómicas, administrativas y académicas. El proyecto se formula en torno a tres tareas complementarias: clasificación de la situación académica final, regresión de la calificación media del segundo semestre y segmentación no supervisada de perfiles. La decisión metodológica central consiste en respetar la disponibilidad temporal de la información para evitar fuga de datos: se comparan escenarios previos al inicio académico con escenarios que incorporan el primer semestre, excluyendo siempre las variables del segundo semestre cuando puedan contaminar la evaluación. Los resultados muestran que el rendimiento del primer semestre es el bloque de información más relevante. En clasificación, la regresión logística one-vs-rest propia alcanza un F1 macro de 0.611 en test y 0.636 en validación cruzada. En regresión, la regresión lineal propia por descenso por gradiente obtiene $R^2 = 0.666$ y RMSE 2.434. En la parte no supervisada, PCA y KMeans identifican dos perfiles con separación moderada, útiles como herramienta descriptiva pero no equivalentes a la variable objetivo.

1 Introducción y objetivos

El abandono, la permanencia y la graduación en educación superior constituyen un problema de modelización especialmente sensible: las métricas predictivas son relevantes, pero solo resultan defendibles si el planteamiento respeta el momento en que cada variable estaría disponible en una situación real. En este trabajo se analiza un conjunto de datos de estudiantes con información de acceso, contexto socioeconómico, situación administrativa, variables macroeconómicas y rendimiento académico de los dos primeros semestres.

El proyecto se organiza en tres tareas. La primera predice la variable objetivo, con las clases abandono, matriculado y graduado. La segunda estima `nota_media_2sem`, excluyendo las variables del segundo semestre por su cercanía a la variable objetivo. La tercera explora perfiles de estudiantes mediante técnicas no supervisadas, sin utilizar la etiqueta objetivo durante el entrenamiento.

La memoria prioriza una lectura metodológica e interpretativa. No se busca únicamente maximizar una métrica, sino comparar escenarios, justificar las decisiones de preprocesado, incorporar modelos base y formular conclusiones prudentes. En particular, se distingue entre predicción inicial, basada solo en información disponible antes del desarrollo del curso, y predicción temprana, donde ya se observa el primer semestre.

2 Exploración inicial y análisis descriptivo

2.1 Descripción general del conjunto de datos

El conjunto de datos contiene 4424 observaciones y 37 variables. Las columnas pueden agruparse en cinco bloques: características demográficas y personales, información de acceso y contexto académico previo, variables socioeconómicas y administrativas, indicadores macroeconómicos agregados y rendimiento académico de primer y segundo semestre. Esta heterogeneidad obliga a combinar tratamiento de variables categóricas, escalado de variables numéricas y una selección cuidadosa de predictores según la tarea.

La variable objetivo presenta desbalanceo moderado: 2209 estudiantes aparecen como graduados (49.93 %), 1421 como abandono (32.12 %) y 794 como matriculados (17.95 %). Por este motivo, en clasificación no se usa únicamente accuracy; se informa también F1 macro, que penaliza con más claridad el bajo rendimiento en clases minoritarias.

2.2 Valores especiales y calidad del dato

No se detectan nulos nativos ni filas duplicadas, pero sí categorías textuales con significado especial. El valor `en_blanco` aparece en las ocupaciones parentales: 17 registros en `ocupacion_madre` y 19 en `ocupacion_padre`. Dado que no representa una profesión interpretable, se trata como dato faltante. En cambio, `desconocido` aparece en las cualificaciones parentales, con 130 casos para la madre y 112 para el padre. En este caso se conserva como categoría porque puede reflejar una situación administrativa informativa, no solo ausencia de dato.




Figura 1: Distribución de la variable objetivo. La clase `matriculado` es la menos frecuente, lo que justifica el uso de métricas macro.

También se revisó la coherencia de las variables académicas. La relación `matriculadas + convalidadas = evaluadas` solo se cumple en el 30.79% de las filas del primer semestre y en el 32.48% del segundo. Al no tratarse de una regla estable del conjunto de datos, no se corrigieron manualmente esas observaciones.

2.3 Notas cero, outliers y variables de contexto

Las calificaciones iguales a cero requieren una interpretación específica. Antes de la limpieza había 718 ceros en `nota_media_1sem` y 870 en `nota_media_2sem`. Cuando la nota es 0 y el número de asignaturas evaluadas también es 0, el valor se interpreta como ausencia de calificación y se transforma en faltante. Esta regla genera 349 nuevos faltantes en la nota del primer semestre y 401 en la del segundo.

Los valores extremos no se eliminan de forma automática. En un contexto educativo, un outlier puede corresponder a una trayectoria real y no necesariamente a un error de medida. Las variables macroeconómicas, por su parte, presentan solo 10 combinaciones únicas, por lo que probablemente describen cohortes o años de entrada. Se mantienen como información contextual, aunque su interpretación se realiza con cautela porque no caracterizan individualmente a cada estudiante.

3 Preprocesado y protocolo experimental

3.1 Limpieza, imputación y codificación

El fichero se carga con `sep=";"`, separador real del CSV. La limpieza común convierte `en_blanco` en faltante, conserva desconocido como categoría y transforma a faltantes los ceros académicos que no corresponden a una calificación evaluada. Esta limpieza se aplica como base, pero después se construyen vistas específicas para clasificación, regresión y clustering.

La imputación, el one-hot encoding y el escalado se ajustan siempre después del split y solo con el conjunto de entrenamiento. Para variables numéricas se utiliza imputación por mediana y estandarización. Para variables categóricas se aplica imputación y codificación one-hot. En clasificación, los faltantes categóricos se mantienen explícitos como `valor_faltante`; en regresión y clustering se imputa por moda para reducir la dimensionalidad final.

3.2 Escenarios temporales

Se definen dos escenarios para estudiar el efecto de la disponibilidad temporal de las variables. El escenario `early` usa únicamente información de entrada y contexto, excluyendo variables de primer y segundo semestre. El escenario `sem1` incorpora el rendimiento del primer semestre y excluye siempre el segundo. Esta distinción es esencial: `early` permite una

Tabla 1: Decisiones metodológicas principales.

Decisión	Justificación
en_blanco como faltante	No describe una categoría semántica real.
desconocido como categoría	Puede contener señal administrativa; la sensibilidad no altera las conclusiones.
Ceros con 0 evaluaciones como faltante	No existe una calificación académica interpretable.
No eliminar outliers globalmente	Un valor extremo puede representar una trayectoria real.
División antes del preprocesado	Evita contaminación entre entrenamiento y test.
Validación cruzada dentro de train	Evalúa robustez sin filtrar información hacia test.




Figura 2: Resultados principales de clasificación. El escenario *sem1* mejora sustancialmente las métricas y la regresión logística OVR es el mejor modelo evaluado.

intervención más temprana, mientras que *sem1* dispone de más señal pero desplaza el uso del modelo a un momento posterior.

En regresión, la variable objetivo es *nota_media_2sem*; por tanto, se eliminan todas las variables contemporáneas del segundo semestre: asignaturas convalidadas, matriculadas, evaluadas, aprobadas, sin evaluación y la propia nota media. Además, se excluyen las filas donde dicha variable queda como faltante tras tratar los ceros sin evaluación.

3.3 Reproducibilidad y validación

Todas las particiones utilizan semilla fija 42. Antes de dividir, las filas se barajan para evitar dependencia del orden original. En clasificación se aplica partición estratificada por clase; en regresión se usa partición aleatoria simple sobre los estudiantes con variable objetivo interpretable. La validación cruzada se realiza exclusivamente dentro de train y vuelve a ajustar el preprocesado en cada fold. En el escenario principal de clasificación quedan 3539 estudiantes en train y 885 en test; tras la codificación se obtienen 240 columnas. En regresión se modelan 4023 estudiantes, con 3218 en train, 805 en test y 216 columnas finales.

4 Implementación y evaluación de modelos supervisados

4.1 Clasificación: situación académica final

La tarea de clasificación predice *objetivo*. Se comparan tres referencias: un modelo base de clase mayoritaria, un kNN propio con distancia de Minkowski y una regresión logística multiclase propia mediante one-vs-rest. La evaluación combina exactitud (accuracy) y F1 macro para reflejar tanto el acierto global como el comportamiento sobre las clases menos frecuentes.

Efecto del escenario temporal. La Figura 2 muestra que el primer semestre incrementa de forma clara la capacidad discriminativa. La regresión logística OVR pasa de 0.641 de accuracy y 0.500 de F1 macro en *early* a 0.736 y 0.611 en *sem1*. La mejora no procede de información del segundo semestre, ya que esas columnas se excluyen en ambos escenarios.

Comparación de modelos. La Tabla 2 resume el rendimiento. kNN supera ampliamente al modelo base, pero la regresión logística OVR obtiene los mejores resultados tanto en test como en validación cruzada. Además, ofrece una interpretación

Tabla 2: Resultados de clasificación en test y validación cruzada.

Modelo	Accuracy	F1 macro
Mayoritaria test	0.499	0.222
kNN test	0.663	0.541
Logística OVR test	0.736	0.611
kNN CV	0.666 ± 0.009	0.543 ± 0.013
Logística OVR CV	0.747 ± 0.017	0.636 ± 0.016




Figura 3: Matriz de confusión normalizada del modelo logístico. La principal dificultad aparece en la clase *matriculado*.

directa mediante pesos por clase. La prueba de sensibilidad sobre desconocido apenas modifica el resultado: la mejor variante obtiene F1 macro 0.615 frente a 0.611 en la configuración principal, por lo que se mantiene la codificación más trazable.

Lectura por clases. El rendimiento no es homogéneo. Para *graduado* el recall alcanza 0.939 y para *abandono* 0.739, mientras que en *matriculado* baja a 0.164. Esta clase intermedia es más ambigua: agrupa estudiantes que continúan matriculados pero que pueden parecerse, según sus variables observadas, tanto a futuros graduados como a casos de abandono.

Los pesos positivos hacia *graduado* se asocian principalmente con asignaturas aprobadas y nota media del primer semestre. Para *abandono* aparecen señales administrativas, como no tener la matrícula al día, junto con variables académicas tempranas.




Figura 4: Comparación temporal en regresión. Incorporar el primer semestre reduce de forma notable el error frente al escenario temprano.

Tabla 3: Resultados de regresión en el escenario sem1.

Modelo	R^2	RMSE	MAE
Media train	-0.003	4.218	2.791
Lineal ecuación normal	0.626	2.575	1.541
Lineal gradiente	0.666	2.434	1.476
Gradiente CV	0.592 ± 0.038	2.739 ± 0.077	1.644 ± 0.030

Estas asociaciones deben entenderse como evidencia predictiva y no como relaciones causales.

4.2 Regresión: calificación media del segundo semestre

La segunda tarea predice `nota_media_2sem`. Se comparan un modelo base que predice la media de train, una regresión lineal por ecuación normal y una regresión lineal por descenso por gradiente. Las dos implementaciones lineales son propias. La formulación excluye las variables del segundo semestre para evitar contaminación directa de la variable objetivo.

Comparación temporal. La Figura 4 confirma que el primer semestre concentra gran parte de la señal predictiva. En `early`, el descenso por gradiente obtiene $R^2 = 0,235$ y RMSE 3.682. En `sem1`, sube a $R^2 = 0,666$ y reduce el RMSE a 2.434. La conclusión principal no es que un optimizador sea universalmente superior, sino que el rendimiento inicial anticipa con fuerza el desempeño posterior.

Diagnóstico e interpretación. La Tabla 3 muestra que ambos modelos lineales superan con claridad al modelo base. En esta partición, el descenso por gradiente queda por delante de la ecuación normal, aunque la diferencia puede depender del split, la codificación y el condicionamiento numérico de la matriz de diseño. La validación cruzada ofrece una estimación más conservadora, con $R^2 = 0,592 \pm 0,038$.

Los coeficientes numéricos más relevantes vuelven a señalar el primer semestre: asignaturas aprobadas y nota media tienen pesos positivos elevados. En sentido contrario aparecen asignaturas matriculadas y convalidadas, edad de acceso y orden de solicitud. La distribución de residuos de la Figura 5 indica errores apreciables en algunos casos, por lo que el modelo es más adecuado para análisis agregado o alerta temprana que para decisiones individuales de alto impacto.

5 Análisis no supervisado: PCA y clustering

La parte no supervisada busca estructuras latentes sin utilizar `objetivo` en el entrenamiento. Se comparan dos espacios: `entry`, con información de entrada, y `sem1`, que añade el primer semestre. Tras imputación, escalado y one-hot encoding, se aplica PCA para conservar el 85 % de la varianza y posteriormente KMeans. La elección de k se evalúa mediante silhouette





Figura 5: Diagnóstico del modelo lineal: convergencia, valores reales frente a predichos y distribución de residuos.



(a) Comparación de espacios.

(b) Selección de k .

Figura 6: Decisiones principales del análisis no supervisado. El espacio `sem1` ofrece una estructura más clara y la mejor opción evaluada es $k = 2$.

en validación por folds.

El espacio `entry` alcanza una silhouette media de 0.136, mientras que `sem1` llega a 0.342. Por ello se adopta `sem1` como espacio principal. Tras el preprocesado se obtienen 230 variables y PCA necesita 26 componentes para conservar el 85 % de la varianza. La mejor solución es $k = 2$, con silhouette media 0.342 en validación cruzada y silhouette final 0.341 sobre todo el conjunto de datos. La estabilidad entre semillas es alta, con ARI medio 1.000, aunque una silhouette alrededor de 0.34 indica separación moderada.

La solución separa un cluster pequeño de 300 estudiantes y otro mayoritario de 4124. El cluster pequeño presenta mayor edad media de acceso (29.37 frente a 22.82), más asignaturas matriculadas, evaluadas y aprobadas en el primer semestre, y una nota media algo superior. También concentra una mayor proporción de graduados: 62.7 % frente a 49.0 % en el cluster grande. Sin embargo, ambos clusters contienen las tres clases, por lo que el agrupamiento no debe interpretarse como una recuperación indirecta de la etiqueta.

Este análisis aporta una lectura complementaria a las tareas supervisadas. Mientras que clasificación y regresión optimizan una variable concreta, el clustering permite describir perfiles de estudiantes. La evidencia apunta a una segmentación gruesa y estable, no a una estructura rica de múltiples grupos claramente diferenciados.

6 Discusión crítica de resultados

El resultado más consistente del proyecto es la importancia del primer semestre. En clasificación mejora el F1 macro y en regresión reduce de forma notable el RMSE. Esta evidencia es coherente con la interpretación educativa: el rendimiento inicial resume adaptación al entorno universitario, hábitos de estudio, dificultades tempranas y posibles incidencias académicas o administrativas.

Al mismo tiempo, esta mejora tiene una contrapartida metodológica. Un modelo basado solo en variables de entrada puede




Figura 7: Visualización de los clusters en las dos primeras componentes principales.

intervenir antes, pero dispone de menos información. Un modelo que espera al primer semestre obtiene mejores métricas, aunque llega cuando parte de la trayectoria ya se ha manifestado. Esta tensión entre anticipación y precisión debe explicitarse antes de trasladar el sistema a una institución educativa.

Las métricas globales tampoco son suficientes por sí solas. En clasificación, la regresión logística alcanza buena accuracy, pero falla con frecuencia en matriculado. En regresión, un RMSE de 2.434 puntos puede ser útil para seguimiento agregado, pero no justifica decisiones individualizadas sin revisión humana. En clustering, la estabilidad de KMeans indica consistencia algorítmica, no necesariamente existencia de grupos educativos naturales.

Por último, las variables administrativas deben interpretarse con prudencia. Señales como matrícula no al día o deuda pueden asociarse al abandono, pero pueden reflejar causas económicas, trámites pendientes u otros factores no observados. El valor práctico del modelo está en priorizar revisiones, abrir preguntas y orientar apoyos, no en etiquetar automáticamente a estudiantes.

7 Limitaciones y posibles mejoras

El estudio está limitado por la información disponible. Variables como motivación, salud, carga laboral, horarios reales, apoyo familiar o cambios personales durante el curso no aparecen en el conjunto de datos y podrían afectar a la trayectoria académica. Además, algunas variables categóricas tienen alta cardinalidad, lo que complica la interpretación de coeficientes tras el one-hot encoding.

La clase matriculado también presenta una ambigüedad conceptual mayor que abandono o graduado. Puede agrupar estudiantes en situaciones muy distintas, lo que ayuda a explicar su bajo recall. Una mejora natural sería reformular parte del




Figura 8: Perfil numérico de los clusters expresado como desviación respecto a la media global.

problema como detección binaria de riesgo de abandono, calibrar probabilidades o ajustar umbrales según costes de error.

En regresión se han utilizado modelos lineales propios por coherencia con las prácticas del curso. Como extensión, podrían compararse modelos no lineales como Random Forest o Gradient Boosting, manteniendo exactamente el mismo protocolo temporal. En no supervisado, sería razonable explorar clustering jerárquico, DBSCAN o distintas codificaciones categóricas para comprobar si la estructura de dos grupos se mantiene.

8 Conclusiones finales

El proyecto cumple las tres tareas del enunciado con una metodología común: limpieza trazable, separación temporal de variables, preprocesado ajustado solo con train, comparación con modelos base y validación cruzada. En clasificación, el mejor modelo es la regresión logística OVR propia, con F1 macro 0.611 en test y 0.636 en validación cruzada. En regresión, el mejor resultado corresponde a la regresión lineal propia por descenso por gradiente, con $R^2 = 0,666$ y RMSE 2.434. En aprendizaje no supervisado, PCA y KMeans identifican dos perfiles con separación moderada.

La conclusión sustantiva es prudente pero clara: el rendimiento del primer semestre es el predictor más informativo del éxito académico posterior. Sin embargo, su uso transforma el problema en una predicción temprana, no previa al inicio de los estudios. Por ello, los modelos deberían emplearse como herramientas de apoyo a la toma de decisiones, siempre acompañados de revisión académica y evitando interpretar las asociaciones como causalidad directa.